



Cahier des charges

Big Data

BENYAMINA Mohamed
Promotion M1 BIG Data IA
2025-2026

Sommaire

1. Contexte et objectif du projet	2
2. Problématique	2
3. Périmètre fonctionnel	3
3.1 Génération ou ingestion de données	3
3.2 Stockage principal distribué	3
3.3 Stockage cloud	3
3.4 Conteneurisation	4
4. Périmètre technique attendu	4
4.1 Architecture	4
4.2 Modélisation Cassandra	4
4.3 Justification Big Data	5
5. Livrables attendus	5
5.1 Dossier technique (rapport écrit)	5
5.2 Dépôt technique	5
5.3 Soutenance orale	6
6. Contraintes	6

1. Contexte et objectif du projet

Dans un contexte où les entreprises doivent collecter, stocker et analyser des volumes croissants de données, il est nécessaire de concevoir des architectures distribuées, scalables et déployables dans des environnements modernes.

Ce projet a pour objectif de concevoir et implémenter une plateforme de gestion et d'analyse de données massives, intégrant les concepts étudiés dans les modules suivants :

- Big Data
- Cloud Storage
- Conteneurisation (Docker)
- Base de données distribuée Cassandra et langage CQL

Vous devrez concevoir une solution cohérente, justifier vos choix techniques et livrer une architecture fonctionnelle.

2. Problématique

Une entreprise souhaite mettre en place une plateforme capable de :

- Collecter des événements (logs applicatifs, données IoT, transactions, clics utilisateurs ou équivalent)
- Stocker ces données de manière scalable
- Permettre des requêtes analytiques rapides
- Garantir disponibilité et tolérance aux pannes
- Être déployable facilement sur tout environnement

L'équipe projet devra proposer une architecture répondant à ces besoins.

3. Périmètre fonctionnel

La solution devra obligatoirement inclure :

3.1 Génération ou ingestion de données

Un système simulant ou collectant des données (format JSON ou équivalent), représentant un flux réaliste (transactions, capteurs, activité utilisateur, etc.).

3.2 Stockage principal distribué

Utilisation de Cassandra pour :

- Concevoir un modèle de données orienté requêtes
- Créer les keyspaces et tables
- Définir partition key et clustering key
- Paramétrer la réplication
- Insérer et interroger les données en CQL

3.3 Stockage cloud

Intégration d'un stockage cloud (ou équivalent local type objet storage) permettant :

- Stockage des données brutes
- Sauvegarde ou archivage
- Séparation stockage / calcul

Les choix devront être justifiés (Data Lake, stockage objet, etc.).

3.4 Conteneurisation

L'ensemble des composants devra être déployé via Docker :

- Cassandra
- Service d'ingestion ou API
- Éventuels services complémentaires

L'utilisation de docker-compose est fortement recommandée.

La gestion des volumes persistants devra être correctement configurée.

4. Périmètre technique attendu

4.1 Architecture

Les étudiants devront produire :

- Un schéma d'architecture global
- Une explication des flux de données
- Une justification des choix technologiques
- Une analyse au regard des principes Big Data (5V, scalabilité, CAP Theorem)

4.2 Modélisation Cassandra

La modélisation devra démontrer :

- Compréhension de la logique orientée requêtes
- Optimisation des partitions
- Gestion de la distribution des données
- Cohérence avec les besoins applicatifs

4.3 Justification Big Data

Le projet devra explicitement démontrer :

- Pourquoi une architecture distribuée est nécessaire
- Pourquoi Cassandra est pertinente dans ce contexte
- Les implications en termes de cohérence, disponibilité et tolérance au partitionnement

5. Livrables attendus

5.1 Dossier technique (rapport écrit)

Le dossier devra contenir :

- Présentation du contexte et des objectifs
- Description détaillée de l'architecture
- Justification des choix techniques
- Modélisation Cassandra
- Exemples de requêtes CQL
- Analyse des performances ou limites
- Discussion des enjeux (scalabilité, sécurité, RGPD, etc.)

5.2 Dépôt technique

Un dépôt contenant :

- Fichiers Docker (Dockerfile, docker-compose.yml)
- Scripts d'initialisation Cassandra
- Scripts d'insertion de données
- Instructions d'installation et de lancement

5.3 Soutenance orale

Présentation comprenant :

- Présentation du problème
- Démonstration technique
- Explication des choix
- Analyse critique du projet

6. Contraintes

- Les solutions doivent reposer sur des outils open source ou gratuits.
- L'architecture doit être reproductible sur une machine standard.
- La conteneurisation est obligatoire.
- Les données utilisées doivent être réalistes (simulation acceptable).
- Le projet doit être réalisé en groupe (2 à 3 étudiants maximum).